Практическая ценность проекта

Проект прогнозирует силу взаимодействия малых молекул с белковыми мишенями. Пользователь - исследователь в области разработки лекарств, которому нужно выбрать перспективные взаимодействия для лабораторной проверки.

Какую задачу решает. Экспериментальная проверка большого числа молекул на разных белках требует времени и ресурсов. Модель помогает сузить список: для известного препарата предлагает дополнительные мишени, а для выбранной мишени ранжирует доступные соединения. Это может поддержать поиск новых применений существующих препаратов.

Как будет использоваться. Пользователь передаёт структуру молекулы в формате SMILES и получает прогноз аффинности для поддерживаемого набора мишеней. Результат сопровождается описанием версии данных, области применимости и ограничений. Прогноз связывания служит гипотезой для эксперимента: он не устанавливает лечебный эффект или безопасную дозировку.

Как оценивать качество. На заранее отложенных молекулах сравниваем ошибку прогноза с простым Random Forest. Основная проверка использует химические каркасы, отсутствующие в обучении. Заказчик также может провести слепую лабораторную проверку отобранных взаимодействий и оценить долю подтверждённых кандидатов и сокращение числа экспериментов.

Ограничения. Публикуемые измерения неравномерно покрывают белки и соединения. Данные разных лабораторий могут противоречить друг другу; отсутствие измерения не означает отсутствия взаимодействия. На необычных структурах качество может снижаться. Текущая постановка поддерживает только изученные мишени. Перенос на новые белки потребует признаков белка и отдельного тестирования.

Реалистичность. Прототип сервиса реализуем на открытых данных ChEMBL и обычных инструментах машинного обучения. Потребуются проверка входных структур, фиксация версий данных и моделей, соблюдение лицензий и защита загружаемых пользователями молекул. Клиническое применение выходит за пределы проекта.

Исследовательская ценность. Проверяем, помогает ли совместное обучение по нескольким мишеням переносить знания на задачи с небольшим количеством измерений. Зафиксированные данные, разбиения и бейзлайн позволяют воспроизводимо сравнивать последующие модели.